INFORME DE INTRODUCCIÓN AL PROYECTO

OpenIoTData

Catálogo abierto para publicar, descubrir y reutilizar datos heterogéneos de sensores IoT

METADATOS DEL DOCUMENTO

- **Estado del Proyecto:** Beta Local (Primer Avance)
- **Licencia de Código:** Apache License 2.0
- **Arquitectura Base:** FastAPI + Next.js + PostgreSQL/PostGIS + MinIO + DuckDB + Keycloak

1. Resumen Ejecutivo y Propósito del Proyecto

OpenIoTData es una plataforma de catálogo abierto concebida para abordar los desafíos críticos en la gestión e intercambio de datos masivos provenientes de dispositivos e infraestructuras de Internet de las Cosas (IoT). En la actualidad, la información generada por sensores suele encontrarse fragmentada, almacenada en formatos heterogéneos y sin mecanismos estandarizados que garanticen su reutilización pública o científica.

Para solucionar este problema, OpenIoTData implementa un monolito modular que integra un plano de control seguro para la gestión de metadatos y un plano de datos de alto rendimiento optimizado para consultas analíticas geoespaciales y temporales sobre archivos en formato Apache Parquet, evitando exponer la base de datos a consultas SQL libres por parte de usuarios externos.

Capacidades Principales de la Plataforma:

- **Publicación Reproducible:** Permite la carga de archivos en formatos CSV, TSV, JSON, NDJSON, Parquet y GeoJSON. El archivo original se conserva intacto de forma inmutable y se genera automáticamente un derivado optimizado en Parquet.
- **Catálogo Público y Búsqueda Segura:** Proporciona descubrimiento, filtros avanzados, paginación y fichas de dataset con consultas parametrizadas seguras.
- **Soporte Geoespacial y Temporal:** Mapeo explícito de tiempo, identidades de sensor y coordenadas mediante cobertura PostGIS y visualización interactiva de puntos.
- **Ingesta Continua por API:** Soporte para envíos de lotes append-only con tokens restringidos por dataset e Idempotency-Key para prevenir duplicaciones de datos.

2. Marco Legal y Investigación de Licencias de Datos Abiertos

Para una plataforma de catálogo abierto como OpenIoTData, el licenciamiento de los datos difiere fundamentalmente del licenciamiento del código fuente del software. Mientras que el software en este repositorio se distribuye bajo la licencia Apache License 2.0, los datos de sensores IoT representan hechos, mediciones o registros cuantitativos que requieren marcos legales orientados explícitamente a la reutilización y a la protección de la autoría.

2.1. Licencias Creative Commons Aplicadas a Datos IoT

Creative Commons Zero (CC0 - Dominio Público)

• **Qué implica:** El autor renuncia voluntariamente a todos los derechos sobre los datos a nivel mundial bajo la ley de derechos de autor, en la medida permitida por la legislación vigente, pasando los datos al dominio público.
• **Ventaja en IoT:** Es la opción idónea para telemetría masiva de sensores (temperatura, humedad, tráfico, calidad del aire). Elimina por completo cualquier fricción legal o requisito burocrático de atribución, permitiendo a investigadores e interfaces analíticas combinar y procesar grandes volúmenes de datos sin restricciones.

Creative Commons Reconocimiento (CC-BY 4.0)

• **Qué implica:** Permite a cualquier entidad compartir, adaptar y comercializar los datos, siempre que se atribuya formalmente la autoría original de la manera especificada por el creador.
• **Ventaja en IoT:** Es excelente para proyectos institucionales, académicos o gubernamentales donde la entidad publicadora requiere mantener el reconocimiento explícito de la fuente para métricas de impacto, citas académicas y rendición de cuentas.

2.2. Gobernanza de Datos y Términos de Servicio (ToS)

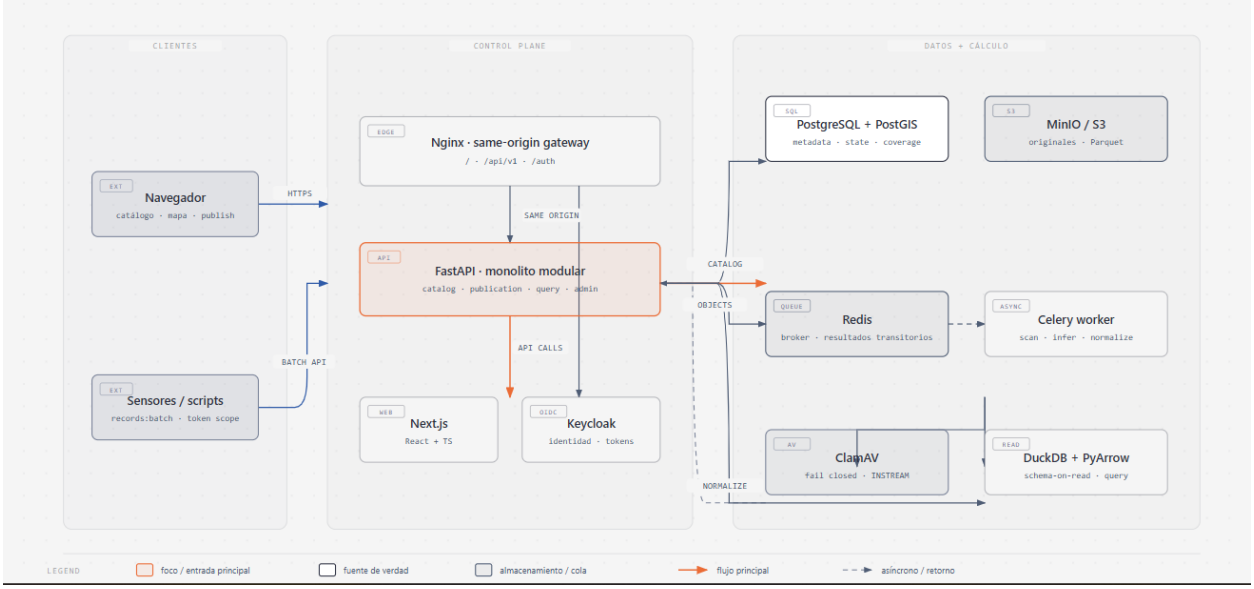
Con el objetivo de blindar legalmente a la plataforma OpenIoTData, los Términos de Servicio exigen el cumplimiento estricto de los siguientes principios al momento en que un usuario o dispositivo sube un dataset:

- **Garantía de Titularidad y Legalidad:** El publicador debe declarar bajo responsabilidad legal que posee los derechos legítimos sobre los datos y que estos no vulneran normativas de privacidad o geolocalización sensible de ciudadanos.
- **Selección Explícita de Licencia:** La plataforma obliga al publicador a declarar una licencia de datos compatible (CC0 o CC-BY) durante la fase de borrador, imposibilitando la publicación sin este requisito.

- **Inmutabilidad y Versionado:** Dado que cada publicación genera un snapshot inmutable, los términos establecen que un dataset publicado no puede borrarse arbitrariamente si ha sido citado o reutilizado, permitiendo en su lugar su archivo o la publicación de una nueva versión.

3. Arquitectura del Sistema y Descripción de Tecnologías

OpenIoTData emplea una estructura de monolito modular basada en FastAPI y Next.js, centralizando el tráfico bajo un gateway de Nginx para mantener un origen único (same-origin). A continuación, se detalla el rol específico y la responsabilidad de cada tecnología utilizada en la plataforma:



Componente	Tecnología	Responsabilidad en el Sistema
Experiencia / UI	Next.js + React + TypeScript	Interfaz de catálogo, visualización de datos, descubrimiento y administración de datasets.
Plano de Control	FastAPI	API modular que gestiona metadatos, permisos, ingesta, trabajos en segundo plano y moderación.
Identidad / Auth	Keycloak (OIDC)	Servidor de autenticación y gestión de usuarios (SSO) mediante Authorization Code + PKCE.
Base de Datos Meta	PostgreSQL + PostGIS	Almacenamiento de datasets, versiones, esquemas inferidos,

		permisos y coberturas geoespaciales.
Almacenamiento Objeto	MinIO (S3 API)	Guarda los archivos originales inmutables, lotes NDJSON y derivados Parquet. Acceso mediante URLs firmadas.
Motor Analítico	DuckDB + Apache Parquet	Procesamiento de inferencia, normalización y consultas parametrizadas sobre Parquet sin expuesto SQL.
Procesamiento Async	Redis + Celery	Cola de tareas y procesamiento pesado desacoplado (escaneo, conversión, derivación).
Seguridad y Salud	ClamAV	Antivirus fail-closed que examina de manera obligatoria todo archivo subido antes del procesamiento.

3.1. Ubicación y Referencia del Diagrama de Arquitectura

El modelo conceptual y de despliegue de la arquitectura de OpenIoTData se ilustra en el esquema principal del proyecto. En la documentación del repositorio, este recurso visual está ubicado en la ruta oficial:

> **UBICACIÓN DE LA IMAGEN EN EL REPOSITORIO:**
> **Ruta relativa:** docs/assets/readme/openiotdata-architecture.png
> **Vista interactiva HTML:** docs/diagrams/openiotdata-architecture.html

Descripción del Diagrama: El esquema muestra la separación entre los clientes (Navegador y Dispositivos IoT), el plano de control gestionado por FastAPI y Nginx, y el plano de datos y cálculo donde conviven MinIO, PostgreSQL/PostGIS, DuckDB y Celery Workers.

4. Estructura del Tema Personalizado en Keycloak

Para la gestión de identidad y autenticación de usuarios, el proyecto se apoya en Keycloak. A continuación se presenta la jerarquía de directorios configurada para el tema personalizado de inicio de sesión:

4.1. Estructura de Archivos del Tema

```
themes/
```

```
└── openiotdata/
    └── login/
        ├── theme.properties
        ├── template.ftl
        ├── login.ftl
        ├── register.ftl
        └── resources/
            └── css/
                └── styles.css
```

Nota de desarrollo futuro: Cabe destacar que en entregas futuras se profundizará a detalle tanto en los fundamentos teóricos como en las especificaciones técnicas de implementación asociadas al desarrollo de estas plantillas y al flujo de autenticación.

5. Conclusiones

- **Solución Estructurada a la Ingesta Heterogénea:** OpenIoTData demuestra ser un modelo eficaz para unificar y catalogar datos masivos de sensores IoT sin sacrificar el formato original, asegurando la trazabilidad e inmutabilidad mediante Parquet.
- **Seguridad y Arquitectura de Control:** La separación del plano de control y el plano de datos, junto con el uso de consultas parametrizadas sobre DuckDB y el escaneo antivirus con ClamAV, establece un entorno de alta seguridad ante contenido potencialmente hostil.
- **Marco Legal Sólido:** La obligatoriedad de declarar licencias explícitas (CC0 o CC-BY) y la inclusión de garantías de titularidad en los Términos de Servicio resguardan legalmente a la plataforma y fomentan la reutilización responsable de la información.
- **Alineación Modular y Escalabilidad:** El diseño desacoplado facilita la evolución continua del proyecto, permitiendo la personalización de capas clave como la autenticación mediante temas en Keycloak y la expansión hacia entornos distribuidos.