FASE 2 — SEGUNDO AVANCE ACTUALIZADO

Evaluación técnica e integración de APIs de generación de imágenes para storyboarding secuencial en agentes autónomos (CrewAI)

Objetivo: Evaluar e integrar APIs de generación de imágenes para storyboards
Avance: Segundo avance actualizado
Entregable: Investigación técnica, matriz comparativa y recomendación arquitectónica
Estado: Investigación y evaluación documental
Nombre: Oscar Manuel Contreras Gacha
Código: 20221020052

1. Objetivos y alcance del avance

1.1. Objetivo general

Evaluar alternativas de APIs para generación de imágenes que puedan integrarse en un flujo de trabajo automatizado mediante agentes autónomos desarrollados con CrewAI, considerando la coherencia visual necesaria para producir storyboards secuenciales de novelas.

1.2. Objetivos específicos

- Identificar proveedores de generación de imágenes con modalidades gratuitas, de bajo coste y profesionales.
- Comparar sus modelos, parámetros de generación y mecanismos para preservar la identidad de personajes y la consistencia estilística.
- Examinar las posibilidades de integración con CrewAI mediante herramientas personalizadas y peticiones HTTP o SDK.
- Contrastar los esquemas de facturación y estimar su impacto en capítulos compuestos por entre cinco y diez viñetas.
- Proponer una arquitectura de enrutamiento que distribuya las solicitudes según el tipo de imagen y el nivel de consistencia requerido.

1.3. Checklist del avance

- ■ Definir las categorías de proveedores que se van a comparar.
- ■ Documentar las capacidades técnicas de ocho alternativas.
- ■ Revisar ejemplos de integración con herramientas de CrewAI.
- ■ Construir una matriz comparativa de coste, consistencia y complejidad.
- ■ Formular una recomendación para el flujo de generación secuencial.

2. Contexto y problemática

La automatización de flujos creativos mediante agentes autónomos debe afrontar la variabilidad estocástica de los modelos de difusión de imágenes. En aplicaciones secuenciales, como el storyboarding de novelas, no basta con generar imágenes aisladas: se necesita mantener la coherencia de los rasgos faciales, la indumentaria, la iluminación y la identidad estilística a lo largo de secuencias de cinco a diez viñetas por capítulo.

Las plataformas abiertas de generación pueden presentar limitaciones operativas para un entorno de producción. Entre los aspectos relevantes se encuentran la dificultad para garantizar parámetros deterministas, la falta de mecanismos de acondicionamiento visual mediante adaptadores como IP-Adapter, PuLID o LoRAs dinámicos, y la variabilidad en los tiempos de procesamiento.

La integración de herramientas personalizadas (*custom tools*) en CrewAI, mediante la clase `BaseTool` o el decorador `@tool`, permite encapsular solicitudes HTTP, validar entradas y almacenar los activos generados en el sistema de archivos local para su posterior ensamblado narrativo.

3. Criterios de evaluación

Las alternativas se analizan con tres dimensiones principales:

- **Capacidad técnica y consistencia visual:** disponibilidad de semillas, referencias de personaje, referencias de estilo, LoRAs, procesos *image-to-image* y parámetros de control.
- **Coste y disponibilidad:** existencia de cuotas gratuitas, créditos iniciales, coste por imagen o megapíxel y condiciones de facturación.
- **Integración:** disponibilidad de API REST o SDK, método de autenticación, complejidad de la petición y facilidad para encapsularla como herramienta de CrewAI.

4. Evaluación de APIs por categoría

4.1. Categoría A: APIs gratuitas o con capa gratuita

Esta categoría reúne servicios que permiten iniciar pruebas con infraestructura administrada y cuotas o créditos gratuitos.

4.1.1. Cloudflare Workers AI

Modelos y capacidades. Cloudflare Workers AI ejecuta modelos de código abierto en su red global de servidores *edge*. Entre los modelos citados para generación visual se encuentran FLUX.1 [schnell] (`@cf/blackforestlabs/flux-1-schnell`) y Stable Diffusion XL Lightning (`@cf/bytedance/stable-diffusion-xl-lightning`). FLUX.1 [schnell] presenta una buena adherencia al *prompt*, pero la infraestructura serverless estándar no permite utilizar directamente adaptadores visuales como PuLID o IP-Adapter en la capa gratuita. Por ello, la continuidad de personajes depende principalmente de fijar la semilla y mantener descripciones consistentes.

El endpoint admite parámetros como `prompt`, `num_steps` (de uno a ocho pasos) y `seed`. FLUX.1 [schnell] utiliza una escala de guía fija en cero, por lo que no procesa *negative prompts* directos.

Integración con CrewAI. La conexión se realiza mediante una petición HTTP autenticada con un API Token y el Account ID de Cloudflare.

```python
import os
import requests
from crewai.tools import tool

@tool("Generador de Imagenes Cloudflare Workers AI")
def generate_cloudflare_image(
    prompt: str, filename: str = "scene.png", seed: int = 42
) -> str:
    """Genera una imagen con FLUX.1 Schnell y la guarda localmente."""
    account_id = os.getenv("CLOUDFLARE_ACCOUNT_ID")
    api_token = os.getenv("CLOUDFLARE_API_TOKEN")
    url = (
        f"https://api.cloudflare.com/client/v4/accounts/"
        f"{account_id}/ai/run/@cf/blackforestlabs/flux-1-schnell"
    )
```

```
    headers = {"Authorization": f"Bearer {api_token}"}
    payload = {"prompt": prompt, "num_steps": 4, "seed": seed}
    response = requests.post(url, headers=headers, json=payload, timeout=60)
    if response.status_code == 200:
        file_path = os.path.join("output_images", filename)
        os.makedirs("output_images", exist_ok=True)
        with open(file_path, "wb") as image_file:
            image_file.write(response.content)
        return f"Imagen guardada exitosamente en {file_path}"
    raise Exception(
        f"Error en Cloudflare API: {response.status_code} - {response.text}"
    )
```

Costes y límites. La investigación reporta una asignación gratuita diaria de 100.000 Neurons. La generación de una imagen consume aproximadamente 170 Neurons, estimándose una capacidad de entre 55 y 100 imágenes gratuitas al día. También se indica un límite de 720 peticiones por minuto para modelos de texto a imagen, ausencia de marcas de agua, uso comercial permitido y reinicio diario de la cuota a las 00:00 UTC.

4.1.2. Hugging Face Inference Providers

Modelos y capacidades. Hugging Face Inference Providers funciona como un enrutador unificado que permite acceder a modelos alojados por proveedores asociados, entre ellos FLUX.1 [schnell] y Stable Diffusion XL. La consistencia depende de la ingeniería de *prompts* y de fijar la semilla, ya que la capa básica del enrutador serverless no permite adjuntar archivos de control o modelos LoRA personalizados. Se reporta soporte para `seed`, `negative_prompt` (en modelos basados en SDXL) y `guidance_scale`.

Integración con CrewAI. Las llamadas se realizan mediante el router https://router.huggingface.co/v1/images/generations, con un formato compatible con OpenAI.

```
import os
import requests
from crewai.tools import tool

@tool("Generador de Imagenes Hugging Face Router")
def generate_huggingface_image(
    prompt: str, filename: str = "hf_scene.png", seed: int = 12345
) -> str:
    """Genera una imagen mediante Inference Providers."""
    token = os.getenv("HF_TOKEN")
    url = "https://router.huggingface.co/v1/images/generations"
    headers = {
        "Authorization": f"Bearer {token}",
        "Content-Type": "application/json",
    }
    payload = {
        "model": "blackforestlabs/FLUX.1-schnell",
        "prompt": prompt,
        "seed": seed,
        "parameters": {"num_inference_steps": 4},
    }
    response = requests.post(url, headers=headers, json=payload, timeout=60)
    if response.status_code == 200:
        data = response.json()
        image_url = data["data"][0]["url"]
        image_bytes = requests.get(image_url, timeout=60).content
        file_path = os.path.join("output_images", filename)
        os.makedirs("output_images", exist_ok=True)
        with open(file_path, "wb") as image_file:
            image_file.write(image_bytes)
        return f"Imagen guardada en {file_path}"
    raise Exception(f"Error HF Router: {response.status_code} - {response.text}")
```

Costes y límites. El documento de investigación reporta un saldo gratuito de 0,10 USD mensuales en créditos de inferencia, suficiente para aproximadamente 20 a 30 generaciones de prueba al

mes. Agotado el saldo, se deben adquirir créditos o contratar PRO por 9 USD mensuales, plan que incluye 2 USD en créditos de inferencia. También se indica un límite de 1.000 llamadas por ventana de cinco minutos en cuentas gratuitas.

4.2. Categoría B: proveedores cloud de bajo coste para modelos open source

Esta categoría agrupa plataformas que ejecutan modelos de código abierto y cobran por imagen o por tiempo de cómputo, ofreciendo opciones de personalización más avanzadas.

4.2.1. Fal.ai

Modelos y capacidades. Fal.ai ofrece modelos de la familia FLUX, incluidos FLUX.1 [dev], FLUX.1 [schnell] y FLUX LoRA, además de arquitecturas como PuLID for FLUX (`fal-ai/flux-pulid`). La investigación califica como muy alta su capacidad de consistencia de personajes. PuLID permite proporcionar una imagen de referencia del rostro para preservar la identidad en varias escenas sin entrenar un LoRA propio. También se reporta la posibilidad de aplicar hasta cuatro LoRAs simultáneos.

Entre los parámetros disponibles se encuentran `seed`, `image_size`, `num_inference_steps`, `guidance_scale` y la ponderación individual de LoRA.

Integración con CrewAI. Se utiliza el SDK oficial `fal_client`.

```python
import os
import requests
import fal_client
from crewai.tools import tool

@tool("Generador Fal.ai PuLID Consistente")
def generate_fal_consistent_character(
    prompt: str, reference_image_url: str,
    filename: str = "pulid_scene.png", seed: int = 42
) -> str:
    """Genera una imagen conservando la identidad del personaje con PuLID."""
    os.environ["FAL_KEY"] = os.getenv("FAL_KEY")
    handler = fal_client.submit(
        "fal-ai/flux-pulid",
        arguments={
            "prompt": prompt,
            "reference_image_url": reference_image_url,
            "seed": seed,
            "num_inference_steps": 20,
            "guidance_scale": 4.0,
            "image_size": "landscape_16_9",
        },
    )
    result = handler.get()
    image_url = result["images"][0]["url"]
    image_data = requests.get(image_url, timeout=60).content
    file_path = os.path.join("output_images", filename)
    os.makedirs("output_images", exist_ok=True)
    with open(file_path, "wb") as image_file:
        image_file.write(image_data)
    return f"Imagen de alta consistencia guardada en {file_path}"
```

Costes. El esquema es de pago por uso. La investigación indica aproximadamente 0,003–0,005 USD por imagen con FLUX.1 [schnell], 0,025 USD con FLUX.1 [dev] a resolución estándar y 0,035 USD por megapíxel para endpoints FLUX LoRA y PuLID. No se reporta una cuota gratuita recurrente y se indica que el contenido generado dispone de derechos de uso comercial.

4.2.2. Replicate

Modelos y capacidades. Replicate aloja miles de modelos, incluidos FLUX.1 [schnell], FLUX.1 [dev] y Stable Diffusion 3.5. Permite desplegar modelos ajustados (*fine-tuned*), utilizar pesos Safetensors y ejecutar procesos *image-to-image*. El parámetro `prompt_strength` permite controlar la fuerza de la transformación de una imagen de entrada. También se reporta soporte para `seed`, `aspect_ratio`, `cfg`, `negative_prompt` y número de pasos.

Integración con CrewAI. Se realiza mediante el SDK oficial `replicate`.

```python
import os
import requests
import replicate
from crewai.tools import tool

@tool("Generador de Imagenes Replicate FLUX")
def generate_replicate_image(
    prompt: str, filename: str = "replicate_scene.png", seed: int = 999
) -> str:
    """Genera una imagen en Replicate con FLUX.1 Dev."""
    os.environ["REPLICATE_API_TOKEN"] = os.getenv("REPLICATE_API_TOKEN")
    input_params = {
        "prompt": prompt,
        "seed": seed,
        "aspect_ratio": "16:9",
        "output_format": "png",
        "output_quality": 90,
    }
    output = replicate.run(
        "black-forest-labs/flux-dev", input=input_params
    )
    image_url = str(output[0])
    image_bytes = requests.get(image_url, timeout=60).content
    file_path = os.path.join("output_images", filename)
    os.makedirs("output_images", exist_ok=True)
    with open(file_path, "wb") as image_file:
        image_file.write(image_bytes)
    return f"Imagen Replicate guardada en {file_path}"
```

Costes. Los precios dependen del modelo y del hardware. Se reportan 0,003 USD por imagen para FLUX.1 [schnell], 0,025 USD para FLUX.1 [dev] y 0,035 USD para Stable Diffusion 3.5 Medium. En hardware dedicado, se indican 0,000225 USD por segundo para Nvidia T4 (aproximadamente 0,81 USD/hora) y 0,0014 USD por segundo para Nvidia A100 de 80 GB (aproximadamente 5,04 USD/hora). Las nuevas cuentas reciben un crédito de prueba único estimado entre 2 y 5 USD.

4.2.3. Together AI

Modelos y capacidades. Together AI proporciona acceso a modelos de difusión como Stable Diffusion XL y FLUX.1 [schnell]. La consistencia narrativa se considera moderada y se apoya en la fijación de la semilla y en la iteración de *prompts*. Se reporta soporte para `seed`, `height`, `width`, `steps`, `n` y `negative_prompt`.

Integración con CrewAI. Se integra mediante peticiones HTTP REST.

```python
import os
import requests
from crewai.tools import tool

@tool("Generador de Imagenes Together AI")
def generate_together_image(
    prompt: str, filename: str = "together_scene.png", seed: int = 777
) -> str:
    """Genera una imagen usando SDXL en Together AI."""
    api_key = os.getenv("TOGETHER_API_KEY")
    url = "https://api.together.xyz/v1/images/generations"
    headers = {
```

```
        "Authorization": f"Bearer {api_key}",
        "Content-Type": "application/json",
    }
    payload = {
        "model": "stabilityai/stable-diffusion-xl-base-1.0",
        "prompt": prompt,
        "width": 1024,
        "height": 576,
        "steps": 30,
        "seed": seed,
    }
    response = requests.post(url, headers=headers, json=payload, timeout=60)
    if response.status_code == 200:
        data = response.json()
        image_url = data["data"][0]["url"]
        image_bytes = requests.get(image_url, timeout=60).content
        file_path = os.path.join("output_images", filename)
        os.makedirs("output_images", exist_ok=True)
        with open(file_path, "wb") as image_file:
            image_file.write(image_bytes)
        return f"Imagen guardada en {file_path}"
    raise Exception(
        f"Error Together AI: {response.status_code} - {response.text}"
    )
```

Costes. Stable Diffusion XL se reporta a 0,0019 USD por megapíxel y FLUX.1 [schnell] a 0,003 USD por imagen. Se indica un saldo promocional inicial de 5 USD después del registro y la validación de un método de pago, sin plan gratuito recurrente.

4.3. Categoría C: APIs profesionales de alta gama

Esta categoría comprende APIs comerciales orientadas a producción, con énfasis en renderizado tipográfico, consistencia estilística y control mediante referencias visuales.

4.3.1. Ideogram API

Modelos y capacidades. Ideogram ofrece modelos 4.5, 4.0 y 3.0, orientados al renderizado de texto dentro de imágenes y a la homogeneidad de estilos gráficos. Su función *Character Reference*, disponible en las versiones citadas, permite proporcionar imágenes de referencia para conservar identidad facial y vestuario. También dispone de *Style Reference* para fijar paleta y composición. Entre sus parámetros se encuentran `aspect_ratio`, `seed`, `negative_prompt`, `character_reference` y opciones de velocidad/calidad.

Integración con CrewAI. La API recibe solicitudes POST en formato JSON.

```
import os
import requests
from crewai.tools import tool

@tool("Generador Ideogram Character Reference")
def generate_ideogram_scene(
    prompt: str, character_img_url: str,
    filename: str = "ideogram_scene.png", seed: int = 101
) -> str:
    """Genera una escena usando referencia de personaje."""
    api_key = os.getenv("IDEOGRAM_API_KEY")
    url = "https://api.ideogram.ai/v1/ideogram-v3/generate"
    headers = {"Api-Key": api_key, "Content-Type": "application/json"}
    payload = {
        "image_request": {
            "prompt": prompt,
            "aspect_ratio": "ASPECT_16_9",
            "model": "V_3_0",
            "magic_prompt_option": "AUTO",
            "seed": seed,
            "character_reference": {
```

```
                "character_repo_specs": [
                    {"image_url": character_img_url}
                ]
            },
        }
    }
    response = requests.post(url, headers=headers, json=payload, timeout=90)
    if response.status_code == 200:
        data = response.json()
        image_url = data["data"][0]["url"]
        image_bytes = requests.get(image_url, timeout=60).content
        file_path = os.path.join("output_images", filename)
        os.makedirs("output_images", exist_ok=True)
        with open(file_path, "wb") as image_file:
            image_file.write(image_bytes)
        return f"Escena de Ideogram guardada en {file_path}"
    raise Exception(
        f"Error Ideogram API: {response.status_code} - {response.text}"
    )
```

Costes. La investigación presenta los siguientes valores por imagen: 0,03 USD para Turbo, 0,06 USD para Default y entre 0,09 y 0,10 USD para Quality en Ideogram 4.0/3.0. El modo Character Reference incrementa el coste, situándolo entre 0,10 USD (Turbo) y 0,20 USD (Quality). Se indica que requiere saldo prepagado y que no ofrece una capa gratuita mensual para desarrolladores.

4.3.2. Recraft API

Modelos y capacidades. Recraft ofrece modelos V4.1, V4.1 Utility y V4 Styles, con generación rasterizada y vectorial. Para mantener la consistencia estilística permite crear un identificador persistente `style_id` mediante imágenes de referencia enviadas al endpoint `/v1/styles`. Las solicitudes posteriores reutilizan ese identificador. El parámetro `style_match` permite seleccionar una adherencia precisa o flexible. También se reportan controles de color RGB y formatos PNG, JPG o SVG.

Integración con CrewAI. Se consume mediante peticiones HTTP REST con autenticación Bearer Token.

```
import os
import requests
from crewai.tools import tool

@tool("Generador Recraft Style Consistent")
def generate_recraft_styled_scene(
    prompt: str, style_id: str,
    filename: str = "recraft_scene.png", seed: int = 42
) -> str:
    """Genera una imagen reutilizando un style_id de Recraft."""
    api_token = os.getenv("RECRAFT_API_TOKEN")
    url = "https://external.api.recraft.ai/v1/images/generations"
    headers = {
        "Authorization": f"Bearer {api_token}",
        "Content-Type": "application/json",
    }
    payload = {
        "prompt": prompt,
        "model": "recraftv4_1",
        "style_id": style_id,
        "random_seed": seed,
        "size": "1024x576",
    }
    response = requests.post(url, headers=headers, json=payload, timeout=60)
    if response.status_code == 200:
        data = response.json()
        image_url = data["data"][0]["url"]
        image_bytes = requests.get(image_url, timeout=60).content
        file_path = os.path.join("output_images", filename)
        os.makedirs("output_images", exist_ok=True)
```

```
        with open(file_path, "wb") as image_file:
            image_file.write(image_bytes)
        return f"Imagen estilizada de Recraft guardada en {file_path}"
    raise Exception(
        f"Error Recraft API: {response.status_code} - {response.text}"
    )
```

Costes. El sistema utiliza unidades de API, con una equivalencia reportada de 1 USD por 1.000 unidades. Recraft V4.1 Raster/Utility cuesta 35 unidades (0,035 USD) por imagen; V4.1 Vector, 80 unidades (0,08 USD); y V4.1 Pro Raster, 210 unidades (0,21 USD). Crear un estilo mediante `/v1/styles` tiene un coste único reportado de 0,005 USD. Se requiere saldo previo para habilitar el token.

4.3.3. Stability AI API

Modelos y capacidades. Stability AI comercializa Stable Diffusion 3.5 en variantes Large, Large Turbo, Medium y Flash. La investigación destaca su capacidad para interpretar descripciones complejas y la disponibilidad de procesos *image-to-image* mediante el parámetro `strength`. Entre los parámetros se encuentran `prompt`, `negative_prompt`, `aspect_ratio`, `seed`, `cfg_scale`, `style_preset` y `output_format`.

Integración con CrewAI. La API utiliza solicitudes multipart/form-data.

```
import os
import requests
from crewai.tools import tool

@tool("Generador Stability AI SD3.5")
def generate_stability_image(
    prompt: str, filename: str = "stability_scene.png", seed: int = 555
) -> str:
    """Genera una imagen con Stable Diffusion 3.5 Large."""
    api_key = os.getenv("STABILITY_API_KEY")
    url = "https://api.stability.ai/v2beta/stable-image/generate/sd3"
    headers = {"Authorization": f"Bearer {api_key}", "Accept": "image/*"}
    files = {"none": ("", "")}
    data = {
        "prompt": prompt,
        "model": "sd3.5-large",
        "aspect_ratio": "16:9",
        "seed": seed,
        "output_format": "png",
    }
    response = requests.post(
        url, headers=headers, files=files, data=data, timeout=60
    )
    if response.status_code == 200:
        file_path = os.path.join("output_images", filename)
        os.makedirs("output_images", exist_ok=True)
        with open(file_path, "wb") as image_file:
            image_file.write(response.content)
        return f"Imagen guardada desde Stability API en {file_path}"
    raise Exception(
        f"Error Stability API: {response.status_code} - {response.text}"
    )
```

Costes. Se reporta una facturación mediante créditos prepagados, con equivalencia de 1 USD por 100 créditos. SD 3.5 Large cuesta 6,5 créditos (0,065 USD) por imagen; Large Turbo, 4 créditos (0,04 USD); Medium, 3,5 créditos (0,035 USD); y Flash, 2,5 créditos (0,025 USD). Las nuevas cuentas reciben 25 créditos de bienvenida tras verificar el registro.

5. Matriz comparativa sintética

La siguiente matriz consolida los datos de la investigación para facilitar la selección según el coste, la consistencia visual y la complejidad de integración.

Tabla 1: Comparación de las ocho APIs evaluadas.

API / proveedor	Categoría	Modelo principal	Coste aprox.	Consistencia de personajes	Integración
Cloudflare Workers AI	A: Gratis	FLUX.1 [schnell] / SDXL	0 USD (cuota diaria)	Básica; prompt y semilla	Baja; REST
Hugging Face Router	A: Gratis	FLUX.1 [schnell] / SDXL	0,10 USD de crédito/mes	Básica; prompt y semilla	Baja; compatible con OpenAI
Fal.ai	B: Cloud OS	FLUX Dev / PuLID	0,003–0,035 USD	Muy alta; PuLID y LoRAs	Muy baja; SDK
Replicate	B: Cloud OS	FLUX Dev / Schnell	0,003–0,025 USD (según modelo)	Alta; LoRAs e Img2Img	Muy baja; SDK
Together AI	B: Cloud OS	SDXL / FLUX Schnell	0,0019–0,003 USD (según unidad/modelo)	Moderada; prompt y semilla	Baja; REST
Ideogram API	C: Pro	Ideogram 4.5 / 3.0	0,03–0,20 USD	Muy alta; Character Reference	Media; JSON
Recraft API	C: Pro	Recraft V4.1	0,035–0,21 USD	Muy alta; `style_id` persistente	Media; gestión de estilos
Stability AI API	C: Pro	SD 3.5 Large	0,025–0,065 USD	Alta; Img2Img y presets	Media; multipart/form-data

6. Análisis comparativo

6.1. Alternativas gratuitas

Cloudflare Workers AI resulta útil para generar fondos, escenarios y planos panorámicos cuando no se requiere conservar con precisión la identidad de un personaje. Su principal ventaja es la cuota gratuita diaria reportada. Sin embargo, la ausencia de adaptadores visuales en la capa considerada limita su aplicación a secuencias con protagonistas recurrentes.

Hugging Face Inference Providers facilita el acceso a distintos modelos mediante un router unificado y un formato compatible con OpenAI. No obstante, el crédito gratuito mensual descrito es reducido y tampoco proporciona, en su capa básica, los mecanismos de referencia visual necesarios para asegurar la continuidad de personajes.

6.2. Proveedores cloud de bajo coste

Fal.ai destaca por la integración de PuLID y LoRAs, que permite reutilizar referencias de personajes. Replicate ofrece flexibilidad mediante modelos ajustados y procesos *image-to-image*. Together AI presenta costes bajos, pero su consistencia depende principalmente de la semilla y de la construcción del *prompt*. Por tanto, las tres opciones responden a necesidades diferentes: identidad visual, flexibilidad de modelos y economía por generación.

6.3. APIs profesionales

Ideogram aporta referencias de personaje y estilo, además de capacidades de renderizado de texto. Recraft se orienta a mantener una identidad gráfica mediante un identificador de estilo reutilizable. Stability AI ofrece controles de generación y procesos *image-to-image*. Estas opciones tienen costes por imagen superiores a algunas alternativas cloud, pero añaden mecanismos de control relevantes para producción.

7. Conclusión y recomendación arquitectónica

Para un flujo de trabajo en CrewAI orientado a generar entre cinco y diez imágenes consecutivas por capítulo, la selección debe equilibrar el coste por generación y la capacidad de mantener la identidad visual de los personajes.

7.1. Opción principal: Fal.ai con PuLID

La investigación recomienda el endpoint `fal-ai/flux-pulid` para storyboards con personajes recurrentes. El agente puede enviar la URL de una imagen base del personaje en cada solicitud, de manera que el modelo preserve sus rasgos faciales a través de distintas escenas. Para un capítulo de diez imágenes, el coste estimado en el documento es de aproximadamente 0,35 USD, calculado sobre la tarifa de 0,035 USD por megapíxel.

7.2. Opción secundaria: Recraft API

Cuando la prioridad sea mantener un estilo artístico uniforme –por ejemplo, novela gráfica, dibujo técnico o estética de cómic retro–, Recraft ofrece un mecanismo de estilo persistente. El agente puede registrar un `style_id` en la primera viñeta y reutilizarlo en las siguientes. Un capítulo de diez imágenes con Recraft V4.1 Raster representa, según la investigación, un coste de 0,35 USD.

7.3. Estrategia híbrida de enrutamiento en CrewAI

Se propone estructurar una herramienta personalizada con selección condicional del proveedor según el contenido de la escena:

- **Fondos y escenarios:** enrutar solicitudes de paisajes o entornos sin personajes principales a Cloudflare Workers AI con FLUX.1 Schnell. La investigación plantea que esta ruta podría cubrir alrededor del 40 % de las imágenes del capítulo sin coste, dentro de la cuota gratuita.
- **Viñetas con personajes:** enrutar escenas con protagonistas o interacciones a Fal.ai con PuLID, o a Recraft API cuando la consistencia estilística sea el requisito dominante.

Esta arquitectura distribuye el cómputo según la necesidad visual de cada viñeta. El informe fuente estima que el presupuesto operativo podría reducirse a menos de 0,20 USD por capítulo mediante este esquema, manteniendo la coherencia narrativa requerida. Esta cifra debe entenderse como una estimación de la arquitectura propuesta y depende de la proporción de imágenes gratuitas y del uso efectivo de cada endpoint.

8. Consideraciones para la implementación

Los ejemplos de código presentados muestran el patrón general de integración, pero antes de incorporarlos a un sistema de producción se deben verificar los esquemas vigentes de cada endpoint, los nombres de modelos disponibles, los formatos de respuesta y las condiciones de facturación.

También es necesario gestionar los errores HTTP, validar que las respuestas contengan una imagen, establecer límites de tiempo y comprobar la descarga de los archivos.

Las credenciales deben almacenarse en variables de entorno y no incluirse directamente en el código fuente. Asimismo, conviene asignar nombres únicos a las imágenes generadas y registrar, junto con cada archivo, el *prompt*, la semilla, el proveedor, el modelo y la referencia visual utilizada. Este registro facilita reproducir pruebas y mantener la trazabilidad de cada viñeta.

9. Fuentes consultadas

Las referencias siguientes corresponden a las fuentes enumeradas en el documento de investigación proporcionado. Los precios, límites y características se reproducen como datos de esa investigación y pueden cambiar según las condiciones comerciales de cada proveedor.

1. Cloudflare Docs, *Workers AI Models*. https://developers.cloudflare.com/workers-ai/models/
2. AIPCF, *AI Provider for Cloudflare*. https://wordpress.org/plugins/aipcf-ai-provider-for-cloudflar
3. Eden AI, *Best Free AI APIs and Open-Source AI Models in 2027*. https://www.edenai.co/post/top-free-generative-ai-apis-and-open-source-models
4. FluxNote, *FLUX Schnell Explained: Free License, Specs, vs Dev*. https://fluxnote.io/models/flash
5. Free LLM API Hub, *Free image generation APIs (Flux, SDXL)*. https://freellmapihub.com/guides/free-image-generation-apis
6. Laozhang AI, *AI Image Generation API Comparison 2026*. https://blog.laozhang.ai/en/posts/ai-image-generation-api-comparison-2026
7. Hugging Face, *Pricing and Billing – Inference Providers*. https://huggingface.co/docs/inference-providers/pricing
8. AionX, *Hugging Face Inference API Free Tier Limits 2026*. https://aionx.co/ai-comparisons/huggingface-inference-api/
9. Runflow, *Free AI Image Generation API, What's Actually Free in 2026?*. https://www.runflow.io/blog/free-ai-image-generation-api-lies
10. Hugging Face, *black-forest-labs/FLUX.1-schnell*. https://huggingface.co/black-forest-labs/FLUX.1-schnell
11. Hugging Face Forums, *Free api for beginners*. https://discuss.huggingface.co/t/free-api-for-beginner179088
12. Ideogram, *Generate with Ideogram 3.0 (legacy) – API Overview*. https://developer.ideogram.ai/v1/api-reference/generate-images/generate-v3
13. Klymentiev, *Hugging Face Inference API Free Tier 2026*. https://klymentiev.com/blog/huggingface-inference-api
14. eesel AI, *Hugging Face pricing explained*. https://www.eesel.ai/blog/hugging-face-pricing
15. fal, *FLUX.1 with LoRAs: Custom AI Image Generator*. https://fal.ai/models/fal-ai/flux-lora
16. fal, *FLUX API for AI models*. https://fal.ai/flux
17. Muapi, *FLUX Dev LoRA: Training*. https://muapi.ai/playground/flux-dev-lora
18. Muapi, *FLUX Schnell: AI Image Generator*. https://muapi.ai/playground/flux-schnell
19. CheckThat.ai, *Replicate Pricing 2026*. https://checkthat.ai/brands/replicate/pricing
20. Modelslab, *Replicate Alternatives: Honest Cost Comparison*. https://modelslab.com/replicate-alternati
21. Replicate, *Stable Diffusion 3.5 Medium – Text to Image API*. https://replicate.com/stability-ai/stable-diffusion-3.5-medium
22. Reddit, *Cheapest API for Image Generation*. https://www.reddit.com/r/generativeAI/comments/1vxn0t9/cheapest_api_for_image_generation/
23. Developers Digest, *Image generation API pricing*. https://www.developersdigest.tech/

models/image-generation
24. Puter Developer, *Ideogram API*. https://developer.puter.com/ai/ideogram/
25. Kie.ai, *Ideogram V3 API*. https://kie.ai/ideogram/v3
26. Ideogram, *Pricing*. https://ideogram.ai/pricing/
27. Ideogram, *API Overview*. https://developer.ideogram.ai/ideogram-api/api-overview
28. OmniaKey, *Ideogram 4.5 Review*. https://omniakey.com/blog/ideogram-4-5-review
29. The Rundown AI, *Ideogram Review*. https://www.therundown.ai/tools/ideogram
30. eesel AI, *Ideogram pricing 2026*. https://www.eesel.ai/blog/ideogram-pricing
31. Segmind, *P-Image-Ideogram Guide*. https://blog.segmind.com/p-image-ideogram-guide-examples-pric
32. Ideogram, *Ideogram API Plans and Billing*. https://docs.ideogram.ai/plans-and-billing/ideogram-api
33. AI Tool Blog, *Recraft API Pricing: Unit Rates and per-Image Costs*. https://aitool-blog.com/recraft/developers/recraft-api-pricing/
34. AI Tool Blog, *Recraft API: Token, Endpoints and style_id Guide*. https://aitool-blog.com/recraft/developers/recraft-api/
35. AI Tool Blog, *Recraft Style Consistency*. https://aitool-blog.com/recraft/guides/recraft-style-consi
36. TypingMind, *Recraft Style Design Skill*. https://www.typingmind.com/skills/calesthio-recraft-develo
37. LiteLLM, *Stability AI provider*. https://docs.litellm.ai/docs/providers/stability
38. Stability AI, *Stable Diffusion 3.5 API*. https://docs.stability.ai/api-reference/generate/stable-diffusion-35
39. GitHub, *MCP server that brings Stability AI to Claude Code*. https://github.com/wynandw87/mcp-server-stability-ai
40. DataCamp, *How to Use the Stable Diffusion 3 API*. https://www.datacamp.com/tutorial/how-to-use-stable-diffusion-3-api