



Evaluación cuantitativa del impacto de ataques de denegación de servicio TCP SYN flood, UDP flood e ICMP flood sobre el desempeño de redes definidas por software mediante modelos de aprendizaje automático

Autor

Jean Pierre Mora Cepeda

Catherine Melisa Maldonado Melenge

Tutor

Paulo Alonso Gaona García.

Doctor en Ingeniería de la Información y del Conocimiento

Universidad Distrital Francisco José De Caldas

Pregrado en Ingeniería de Sistemas

Línea de investigación en Redes de Comunicaciones

Bogotá, Colombia

Agosto de 2026

Contenido

Identificación del problema	2
Objetivos de la monografía	4
Objetivo general.....	4
Objetivos específicos	5
Justificación	5
Plan de trabajo.....	6
Fase 1: Fundamentación teórica y revisión del estado del arte.....	6
Fase 2: Diseño e implementación del entorno experimental.....	6
Fase 3: Diseño experimental y captura de métricas	7
Fase 4: Construcción de dataset.....	7
Fase 5: Cuantificación y análisis comparativo del impacto.....	7
Fase 6: Desarrollo y entrenamiento de modelos de aprendizaje automático.....	7
Fase 7: Análisis de resultados, conclusiones y redacción final	7
Cronograma	8
Bibliografía	9

Identificación del problema

Las Redes Definidas por Software (SDN, Software Defined Networking) han transformado la manera en que se diseñan, gestionan y operan las infraestructuras de red modernas al desacoplar el plano de control del plano de datos y permitir una gestión centralizada, programable y flexible del tráfico. Sin embargo, esta misma centralización introduce un punto único de falla, si el controlador o los canales de comunicación entre el controlador y los switches se ven comprometidos, toda la red puede verse afectada. (Alashhab et al., 2024)

Precisamente por esta razón, la arquitectura SDN resultan especialmente sensible frente a los ataques de Degeneración de Servicio (DoS) y Degeneración de Servicio Distribuido (DDoS). Ataques como TCP SYN flood, UDP flood e ICMP flood son capaces de saturar el canal de comunicación entre el plano de datos y el plano de control, agotar los recursos de las tablas de flujo de los conmutadores OpenFlow y sobrecargar el procesamiento del controlador mediante mensajes Packet-In generados por flujos desconocidos, lo que puede derivar en la degradación o incluso el colapso total de la red (Eliyan & Di Pietro, 2021).

A la par de este panorama, el avance del aprendizaje automático ha abierto una vía adicional para abordar el problema: en lugar de depender exclusivamente de reglas estáticas o de la observación manual por parte de un administrador, hoy es posible analizar el comportamiento de una red a partir de sus propias métricas (tráfico, latencia, uso de CPU del controlador, número de flujos, entre otras) para detectar y caracterizar este tipo de ataques de manera sistemática (Abdi et al., 2024; Alashhab et al., 2024).

A pesar de que la literatura reciente sobre seguridad en SDN ha crecido de manera considerable, la investigación se ha concentrado mayoritariamente en el desarrollo de mecanismos de detección y clasificación binaria de tráfico malicioso mediante aprendizaje automático, dejando en segundo plano la cuantificación sistemática del impacto que estos ataques generan sobre el desempeño operativo de la red.

Esta limitación se evidencia de varias formas:

1. **Evaluación incidental del impacto:** En la mayoría de los estudios revisados, las métricas de desempeño (uso de CPU del controlador, throughput, latencia, pérdida de paquetes, entre otras) se reportan únicamente como evidencia secundaria para validar la eficacia de un sistema de detección o mitigación, y no como el objeto central de análisis.
2. **Ausencia de un enfoque de intensidad variable:** Los experimentos suelen limitarse a comparar dos escenarios discretos sin explorar cómo varía la

magnitud de la degradación de la red en función de la intensidad del ataque (tasa de paquetes por segundo, número de fuentes atacantes, duración. Entre otros factores). Esto impide establecer relaciones dosis-respuesta entre la severidad del ataque y su efecto sobre el desempeño de la red.

3. **Uso limitado del aprendizaje automático como herramienta analítica:** El aprendizaje automático se emplea predominantemente para tareas de clasificación (detección de ataques), mientras que su potencial para modelar y predecir la magnitud del impacto en función del tipo e intensidad del ataque, así como para identificar mediante técnicas de interpretabilidad qué variables son más determinantes en la degradación observada, permanece prácticamente inexplorado
4. **Comparaciones poco sistemáticas entre tipos de ataques:** Si bien distintos estudios abordan ataques TCP SYN flood, UDP flood e ICMP flood de forma individual o conjunta, no es común encontrar investigaciones que comparen de manera cuantitativa y controlada la severidad diferencial de cada tipo de ataque sobre múltiples variables de red simultáneamente, en entornos emulados equivalentes

Esta carencia impide contar con evidencia empírica robusta y generalizable sobre cuánto y cómo degrada cada tipo de ataque DoS el desempeño de una red SDN, información que resulta fundamental tanto para el diseño de mecanismos de mitigación más eficientes y focalizados, como para la priorización de recursos de seguridad según el nivel de riesgo real que representa cada vector de ataque.

En consecuencia, surge la siguiente pregunta de investigación:

¿Cuál es el impacto cuantificado, en términos de degradación del desempeño, de los ataques de Denegación de Servicio TCP SYN flood, UDP flood e ICMP flood sobre una red SDN emulada, y en qué medida su tipo e intensidad pueden ser modelados y explicados mediante técnicas de aprendizaje automático?

Dado que el concepto de “impacto” admite múltiples interpretaciones dentro de la literatura de seguridad de redes, resulta necesario precisar su alcance para efectos de esta investigación. Se entenderá por impacto la variación negativa que experimenta el desempeño de una red SDN al ser sometida a un ataque de Denegación de Servicio, medida respecto a un escenario base de operación sin ataque, bajo condiciones experimentales controladas y equivalentes. Esta variación se expresará a través de un conjunto de métricas cuantitativas agrupadas en tres dimensiones:

- **Desempeño de red:** throughput, latencia y pérdida de paquetes, como indicadores directos de calidad de servicio percibida por el tráfico legítimo (Kaur et al., 2025; Ganeshan & Ramasamy, 2026).
- **Desempeño del controlador:** Utilización de CPU y memoria del controlador SDN, así como el tiempo de respuesta ante evento de red, como indicadores del grado de sobrecarga inducido sobre el plano de control. (Eliyan & Di Pietro, 2021; Abdi et al., 2024)
- **Comportamiento de las tablas de flujo:** Número de flujos activos y tasa de generación de mensajes Packet-In como indicadores de la carga generada por el ataque sobre los conmutadores y la comunicación entre el plano de datos y el plano de control.

Objetivos de la monografía

Objetivo general

Evaluar cuantitativamente de los ataques de Degeneración de Servicios TCP SYN flood, UDP flood e ICMP flood sobre el desempeño de una red definida por software emulada, mediante el desarrollo de modelos de aprendizaje automático que permitan modelar y explicar dicho impacto en función del tipo e intensidad del ataque.

Objetivos específicos

1. Diseñar e implementar un entorno experimental de red definida por software emulada, aislado y reproducible, que permita ejecutar de manera controlada por los ataques TCP SYN flood, UDP flood e ICMP flood bajo distintos niveles de intensidad.
2. Definir y capturar un conjunto de métricas de desempeño de red, de controlador y tablas de flujo (throughput, latencia, pérdida de paquetes, utilización de CPU y memoria del controlador, tiempo de respuesta, número de flujos activos y tasa de mensajes Packet-In), tanto en un escenario base sin ataque como en escenarios bajo ataque con intensidad variable.
3. Construir un dataset propio y balanceado a partir de los datos capturados, que integre las métricas anteriores junto con la identificación del tipo e intensidad de ataque asociado a cada observación.
4. Cuantificar y comparar la severidad diferencial del impacto generado por cada tipo de ataque sobre las métricas del ataque sobre las métricas de desempeño definidas, estableciendo la relación entre la intensidad del ataque y la magnitud de la degradación observada.
5. Desarrollar y entrenar modelos de aprendizaje automático capaces de modelar y predecir la magnitud del impacto sobre el desempeño de la red a partir del tipo e intensidad del ataque.

Justificación

El estudio de la seguridad en Redes Definidas por Software constituye un campo de investigación en expansión debido a la naturaleza misma de esta arquitectura: la separación entre el plano de control y el plano de datos, si bien aporta programabilidad y centralización, introduce también un punto único de falla que puede ser explotado mediante ataques de Denegación de Servicio (Abdi et al., 2024; Wu et al., 2020). Esta investigación aporta valor teórico al desplazar el foco habitual de la literatura centrada en la detección y clasificación binaria de tráfico malicioso hacia la cuantificación sistemática del impacto que estos ataques generan sobre múltiples dimensiones del desempeño de la red (tráfico, controlador y tablas de flujo). Al establecer relaciones dosis-respuesta entre la intensidad del ataque y la magnitud de la degradación, el proyecto contribuye a llenar un vacío conceptual identificado en la literatura reciente, permitiendo comprender no solo si un ataque afecta la red, sino cuánto y de qué manera lo hace según su tipo e intensidad.

Desde el punto de vista metodológico, el proyecto propone un enfoque experimental controlado y replicable, mediante la emulación de una red SDN sometida a distintos tipos e intensidades de ataques (TCP SYN flood, UDP flood e ICMP flood), lo que permite generar evidencia empírica comparable entre escenarios. Adicionalmente, la incorporación de técnicas de aprendizaje automático no se limita a la tarea clásica de detección, sino que se extiende a la modelación predictiva de la magnitud del impacto y a la interpretabilidad de los modelos, con el fin de identificar qué variables de red resultan más determinantes en la degradación observada (Ganeshan & Ramasamy, 2026). Esto constituye un aporte metodológico relevante, dado que la literatura actual explota de forma limitada el potencial analítico más allá del clasificatorio del aprendizaje automático en este dominio.

En el plano práctico, contar con evidencia cuantitativa y comparativa sobre la severidad diferencial de cada tipo de ataque permite a administradores de red y equipos de seguridad priorizar recursos de mitigación de forma más eficiente, focalizando esfuerzos en los vectores de ataque que representan mayor riesgo real para el desempeño de la infraestructura (Eliyan & Di Pietro, 2021; Kaur et al., 2025). Comprender cómo se comporta el controlador, los conmutadores OpenFlow y la calidad de servicio percibida por el tráfico legítimo ante distintos niveles de intensidad de ataque aporta insumos concretos para el diseño de mecanismos de defensa más eficientes y menos genéricos, en lugar de soluciones basadas únicamente en la detección binaria de tráfico malicioso.

Las redes SDN son cada vez más utilizadas en infraestructuras críticas, centros de datos y proveedores de servicios en la nube, por lo que su disponibilidad y estabilidad impactan directamente a un número creciente de usuarios y organizaciones (Tankovic et al., 2025). Al aportar conocimiento sobre cómo y en qué magnitud los ataques DoS

degradan estas redes, la investigación contribuye indirectamente a fortalecer la resiliencia de servicios digitales de los cuales depende un amplio espectro de la sociedad, desde empresas hasta usuarios finales.

Plan de trabajo

Fase 1: Fundamentación teórica y revisión del estado del arte

Esta fase comprende la consolidación del marco teórico del proyecto y la revisión sistemática de la literatura relacionada con ataques de Denegación de Servicios en redes definidas por software, los dataset existentes, los controladores y topologías empleados en estudios previos, así como las métricas y algoritmos de aprendizaje automático utilizados con mayor frecuencia. El resultado de esta fase permite sustentar formalmente el vacío investigativo identificado y orientar las decisiones técnicas de las fases siguientes.

Fase 2: Diseño e implementación del entorno experimental

En esta fase se lleva a cabo la construcción del entorno de red definida por software emulado sobre la máquina de ciberseguridad disponible. Dicho proceso incluye la definición de la topología de red, la selección y configuración del controlador SDN, el despliegue de los conmutadores virtuales mediante Open vSwitch, y la configuración del emulador de red correspondiente. El entorno resultante deberá garantizar condiciones de aislamiento respecto a redes externas, así como su reproducibilidad para efectos de validación posterior.

Fase 3: Diseño experimental y captura de métricas

Esta fase corresponde a la definición formal de los escenarios experimentales que serán objeto de estudio, considerando un escenario base de operación normal y escenarios bajo ataque con distintos niveles de intensidad para cada uno de los vectores considerados (TCP SYN flood, UDP flood e ICMP flood). Se establece igualmente el número de repeticiones por escenario y se implementan los mecanismos necesarios para la captura de las métricas de red, de controlador y de tablas de flujo previamente definidas.

Fase 4: Construcción de dataset

A partir de los datos obtenidos en la fase anterior, se realiza el procesamiento, limpieza y estructuración de la información con el fin de consolidar un dataset propio, debidamente etiquetado según el tipo de intensidad del ataque asociado a cada observación. Esta fase incluye igualmente la verificación del balance entre clases y la separación del conjunto de datos en subconjuntos de entrenamiento, validación y prueba.

Fase 5: Cuantificación y análisis comparativo del impacto

Esta fase comprende el análisis estadístico y comparativo del comportamiento de las métricas de desempeño frente a cada tipo e intensidad de ataque evaluado, con el propósito de establecer la severidad diferencial de cada vector de ataque y determinar la relación existente entre la intensidad del ataque y la magnitud de la degradación observada sobre la red.

Fase 6: Desarrollo y entramiento de modelos de aprendizaje automático

En esta fase se procede a la selección, entrenamiento y ajuste de los modelos de aprendizaje automático que permitirán modelar y predecir la magnitud del impacto sobre el desempeño de la red en función del tipo e intensidad del ataque, empleando para ello el dataset construido en la fase 4 y los hallazgos obtenidos en la fase 5.

Fase 7: Análisis de resultados, conclusiones y redacción final

Finalmente, se realiza la integración de los hallazgos obtenidos en las fases anteriores, contrastándolos con la pregunta de investigación planteada y con los antecedentes revisados en el estado del arte. Esta fase culmina con la redacción de las conclusiones del proyecto, la identificación de sus limitaciones y posibles líneas de trabajo futuro, así como la consolidación del documento final.

Cronograma

Fase	Semanas	Duración	Entregable clave
Fase 1 – Fundamentación teórica y estado del arte	1 – 6	6 sem	Marco teórico y estado del arte documentado
Fase 2 – Diseño e implementación del entorno experimental	5 – 11	7 sem	Entorno SDN emulado funcional y validado
Fase 3 – Diseño experimental y captura de métricas	10 – 17	8 sem	Escenarios definidos + métricas capturadas (repeticiones completas)
Fase 4 – Construcción del dataset	16 – 21	6 sem	Dataset propio,

			etiquetado y particionado
Fase 5 – Cuantificación y análisis comparativo del impacto	20 – 27	8 sem	Análisis comparativo de severidad por vector de ataque
Fase 6 – Desarrollo y entrenamiento de modelos de ML	26 – 37	12 sem	Modelos entrenados y validados con métricas de desempeño
Fase 7 – Análisis de resultados, conclusiones y redacción final	36 – 50	15 sem	Documento final de monografía
Buffer / ajustes finales y preparación de sustentación	51 – 52	2 sem	Documento revisado y presentación de sustentación

Bibliografía

- Abdi, A. H., Audah, L., Salh, A., Alhartomi, M. A., Rasheed, H., Ahmed, S., & Tahir, A. (2024). Security Control and Data Planes of SDN: A Comprehensive Review of Traditional, AI, and MTD Approaches to Security Solutions. *IEEE Access*, 12, 69941–69980. <https://doi.org/10.1109/ACCESS.2024.3393548>
- Alashhab, A. A., Zahid, M. S., Isyaku, B., Elnour, A. A., Nagmeldin, W., Abdelmaboud, A., Abdullah, T. A. A., & Maiwada, U. D. (2024). Enhancing DDoS Attack Detection and Mitigation in SDN Using an Ensemble Online Machine Learning Model. *IEEE Access*, 12, 51630–51649. <https://doi.org/10.1109/ACCESS.2024.3384398>
- Eliyan, L. F., & Di Pietro, R. (2021). DoS and DDoS attacks in Software Defined Networks: A survey of existing solutions and research challenges. *Future Generation Computer Systems*, 122, 149–171. <https://doi.org/10.1016/J.FUTURE.2021.03.011>
- Ganeshan, S., & Ramasamy, R. K. (2026). A Systematic Review of Machine-Learning-Based Detection of DDoS Attacks in Software-Defined Networks. In *Future Internet* (Vol. 18, Number 2). Multidisciplinary Digital Publishing Institute (MDPI). <https://doi.org/10.3390/fi18020109>

- Kaur, A., Rama Krishna, C., & Patil, N. V. (2025). A comprehensive review on Software-Defined Networking (SDN) and DDoS attacks: Ecosystem, taxonomy, traffic engineering, challenges and research directions. *Computer Science Review*, 55, 100692. <https://doi.org/10.1016/J.COSREV.2024.100692>
- Tankovic, A., Dervisevic, E., Mehic, M., & Kaljic, E. (2025). A Survey on Data Plane Security in Software-Defined Networks: Toward Adaptive Security of Data Planes. *IEEE Access*, 13, 97058–97093. <https://doi.org/10.1109/ACCESS.2025.3575494>
- Wu, Y., Yan, Z., Zhao, Z., & Al-Dubai, A. (2020). Editorial: Special issue on SDN-based wireless network virtualization. In *Concurrency and Computation: Practice and Experience* (Vol. 32, Number 16). John Wiley and Sons Ltd. <https://doi.org/10.1002/cpe.5444>